Dataset definitivo y documentado — Reconocimiento de rayas (Equipo 2, IdentiMar)

Proyecto Integrador I · Grupo 9 · Ingeniería de Sistemas, Universidad de Antioquia

Andrés Camilo Areiza Londoño · Karen Cardona Gutiérrez · Juan Pablo Valencia Martínez · Sebastián Flórez Jaramillo

Docente: David S. Fernández Mc Cann · Entrega: 29 de octubre de 2026

1. Resumen

El dataset contiene **286 imágenes** de cuatro especies de rayas reportadas para el Caribe colombiano y la cuenca del Atrato (Golfo de Urabá). Cada imagen tiene un registro en el inventario con especie, fuente, autor u observador, licencia, fecha, ubicación, ambiente, condición del organismo y partición asignada. El dataset se divide en tres particiones: **198 imágenes de entrenamiento, 59 de validación y 29 de prueba**. Este documento acompaña al archivo `Inventario_Dataset_Consolidado_IdentiMar.xlsx`, que es el inventario definitivo imagen por imagen.

El dataset se usó para entrenar el modelo definitivo (V7: YOLOv8n, Ultralytics 8.4.170, sobremuestreo 3× de *P. magdalenae* con script idempotente). El export de Roboflow con el que se entrenó (`IdentiMar-Rayas-2`, versión 2) tiene 58 imágenes de validación, una menos que el inventario (ver sección 3). Las métricas del modelo se documentan en el informe de evaluación, no aquí.

2. Especies seleccionadas

Se investigaron cinco especies. La raya de profundidad (*Rajella purpuriventralis*) se descartó: es bentónica (730 a 2.010 m) y no tiene respaldo fotográfico confirmado ni relación con la pesca artesanal de superficie. Las cuatro especies finales son:

ID de clase	Nombre común	Nombre científico	Familia	Estado UICN (según inventario)
0	Raya gavilán	*Aetobatus narinari*	Aetobatidae	En peligro (Lista Roja UICN)
1	Raya látigo	*Hypanus guttatus*	Dasyatidae	Casi amenazado (Lista Roja UICN)
2	Raya del Magdalena	*Potamotrygon magdalenae*	Potamotrygonidae	Vulnerable (UICN Colombia)
3	Raya chupare	*Styracura schmardae*	Potamotrygonidae	En peligro (Lista Roja UICN)

Los IDs de clase están confirmados en la ficha del modelo (`FICHA_MODELO.md`, congelada el 14 de octubre de 2026): 0 = *Aetobatus_narinari*, 1 = *Hypanus_guttatus*, 2 = *Potamotrygon_magdalenae* y 3 = *Styracura_schmardae*.

La disponibilidad real de imágenes se verificó antes de fijar metas mediante las APIs de GBIF e iNaturalist. *P. magdalenae* es el cuello de botella: es endémica de Colombia, por lo que no existe un volumen mayor de imágenes fuera de fuentes colombianas.

3. Composición y particiones

Especie	Meta	Total	Train	Validación	Prueba
Hypanus guttatus	80	81	55	18	8
Aetobatus narinari	80	80	56	16	8
Styracura schmardae	80	80	56	16	8
Potamotrygon magdalenae	50	45	31	9	5
Total	**290**	**286**	**198 (69,2 %)**	**59 (20,6 %)**	**29 (10,1 %)**

La meta de *P. magdalenae* se redujo de 80 a 50 por la disponibilidad real de imágenes y finalmente se reunieron 45. Todas las imágenes del inventario quedaron marcadas como aptas para el dataset y ninguna queda sin asignar.

La carpeta train del export tiene 876 imágenes: las fuentes con sus versiones aumentadas y 279 copias del sobremuestreo de *P. magdalenae*.

Criterio de partición. Cada imagen pertenece a una única partición (train, validación o prueba). La aumentación de datos se aplicó únicamente sobre train, y el sobremuestreo de *P. magdalenae* (×3) solo sobre la carpeta train, de modo que validación y prueba quedaron intactas.

Conjuntos independientes adicionales. Las 20 imágenes del conjunto ciego y las 13 imágenes externas de desarrollo no forman parte de las 286 y no se usaron para entrenar ni para elegir el modelo (ver sección 8).

4. Procedencia

Fuente	Hypanus	Aetobatus	Styracura	Potamotrygon	Total
iNaturalist	80	65	80	25	250
GBIF	1	15	0	0	16
Wikimedia Commons	0	0	0	1	1
Muséum national d'Histoire naturelle (MNHN)	0	0	0	1	1
Sin fuente verificada	0	0	0	18	18

Para cada imagen el inventario guarda la URL o referencia de origen y el autor u observador. Las 20 imágenes de *P. magdalenae* sin fuente verificada proceden de páginas de tiendas de acuarismo, una publicación de Facebook, una figura de SciELO, la Agencia de Noticias de la Universidad Nacional y un sitio de ictiología (fishbiosystem.ru). En esos registros el autor figura como «Desconocido».

Procedencia geográfica. Solo 32 de las 286 imágenes (11 %) tienen ubicación en Colombia: 24 de *P. magdalenae*, 4 de *H. guttatus*, 3 de *S. schmardae* y 1 de *A. narinari*. El resto proviene de Brasil, Belice, México, Trinidad y Tobago, Florida, Panamá, Costa Rica y otros países del Caribe. Además, iNaturalist ocultó las coordenadas de 23 registros y las difuminó en 46.

Fechas. Las fechas de las fotos van de 1993 a 2026. 19 imágenes no tienen fecha conocida; se normalizaron al formato AAAA-MM-DD.

5. Licencias

Licencia	Imágenes	Observación
CC-BY-NC	234	No permite uso comercial
CC-BY	24	Exige atribución
CC-BY-NC-SA	4	No comercial; derivados con la misma licencia
CC-BY-NC-ND	2	No comercial; sin obras derivadas (IMG-0086 en prueba, IMG-0250 en validación)
CC-BY-SA	1	Derivados con la misma licencia (IMG-0165)
CC0	1	Dominio público (IMG-0133)

Condiciones de uso adoptadas. El dataset se usa con fines académicos y de investigación dentro del proyecto IdentiMar. La licencia predominante (81 %) es CC-BY-NC, por lo que las imágenes no deben redistribuirse públicamente ni usarse comercialmente. El inventario conserva la URL y la atribución de cada autor; las imágenes anotadas están alojadas en un proyecto público de Roboflow.

Licencia no verificada. Las 20 imágenes sin fuente verificada de *P. magdalenae* figuran en el inventario como Desconocido, se consideran de uso académico interno y no redistribuible.

6. Anotaciones

Aspecto	Descripción
Tarea	Detección de objetos: una caja por organismo, con la especie como clase
Herramienta	Roboflow
Formato	YOLO (etiquetas .txt con coordenadas normalizadas)
Versión del dataset	v2: anotaciones corregidas y 3 imágenes borrosas sustituidas
Preprocesamiento	Auto-orientación y redimensionado a 640×640
Aumentación (solo train)	Flip horizontal; rotación ±15°; hue ±10°; saturación ±20 %; brillo ±20 %; exposición ±10 %; blur hasta 1,5 px; ruido

Aspecto	Descripción
	hasta 3 %
Sin aumentación	Flip vertical, shear y escala de grises (alteran el disco o el patrón de manchas, que son rasgos diagnósticos)
Sobremuestreo	*P. magdalenae* ×3 solo en train: de 597 a 876 imágenes (372 con la clase, 42,5 % de train)
Criterio de la caja	caja ajustada al disco, cola incluida

Los rasgos diagnósticos que guiaron la anotación y la curaduría fueron: hocico puntiagudo y tubérculos dorsales en *H. guttatus*; patrón de manchas blancas sobre fondo oscuro en *A. narinari*; tubérculos grandes en los hombros y disco casi circular en *S. schmardae*. Para *P. magdalenae* no se encontró una descripción de patrón verificada en la literatura consultada, por lo que se compararon visualmente ejemplares confirmados.

7. Calidad y curaduría

Se registró una imagen por fila. Todas las 286 imágenes están marcadas como aptas. Se incluyeron deliberadamente fotos con calidad de smartphone real (desenfoque leve, iluminación variable, fondo turbio) para reducir la brecha entre lo medido y el uso real por pescadores. Se reemplazaron 3 imágenes borrosas en la versión v2.

Composición por ambiente y condición del organismo:

Condición del organismo	Hypanus	Aetobatus	Styracura	Potamotrygon	Total
Vivo en agua	25	76	77	8	186
Capturado o desembarcado	34	0	0	29	63
Fallecido	20	4	2	4	30
Espécimen de colección	2	0	0	0	2
Desconocido o sin registrar	0	0	1	4	5

Por ambiente: 223 marino, 51 desconocido, 10 dulceacuícola y 2 sin registrar.

8. Sesgos y limitaciones conocidas

1. **Contexto correlacionado con la clase.** Las 63 imágenes de ejemplares capturados o desembarcados son todas de *H. guttatus* o *P. magdalenae*, mientras que *A. narinari* y *S. schmardae* aparecen casi siempre vivas en el agua. El modelo podría usar el contexto además de la morfología. Es coherente con las dificultades observadas con fotos fuera del agua.
2. **Tamaño reducido de *P. magdalenae*.** 45 imágenes, con solo 9 en validación y 5 en prueba. Una fracción proviene del comercio como pez ornamental (posible sesgo de cautiverio), y la clase se compensó con sobremuestreo ×3.

3. **Procedencia geográfica.** Solo el 11 % de las imágenes se tomó en Colombia, y la mayoría de *A. narinari*, *H. guttatus* y *S. schmardae* viene de otros países del Caribe y de Brasil.

9. Imágenes nuevas independientes

Conjunto	Imágenes	Uso
Conjunto ciego	20	Evaluado una sola vez con el modelo congelado (V7) a través de la API. Sin duplicados internos ni frente al dataset completo (hash perceptual)
Imágenes externas de desarrollo	13	Verificación informal durante el desarrollo; no son una evaluación ciega

Los resultados sobre estos conjuntos se presentan en el informe de evaluación.

10. Reproducibilidad y archivos

- **Inventario definitivo:** `Inventario_Dataset_Consolidado_IdentiMar.xlsx`. Incluye las hojas Resumen, Inventario (286 filas), Anotaciones y Verificaciones.
- **Identificador de imagen:** `IMG-0001` a `IMG-0286`, único en todo el inventario.
- **Modelo asociado:** V7, YOLOv8n de 72 capas y 3.006.428 parámetros, Ultralytics 8.4.170, entrenado con epochs=100, imgsz=640, batch=16 y patience=20 y seed=0. Pesos best.pt de 6,26 MB (sha256 d35ef9c3…, mejor época 93), registrados en la ficha del modelo.
- **Versión del dataset:** v2 más sobremuestreo ×3 de *P. magdalenae* en train.