Módulo de visión artificial basado en YOLO para la clasificación de especies de rayas del Urabá antioqueño — Informe de Avance

Proyecto Integrador I — Grupo 9 — Ingeniería de Sistemas, Universidad de Antioquia

Andrés Camilo Areiza Londoño · Karen Cardona Gutiérrez · Juan Pablo Valencia Martínez · Sebastián Flórez Jaramillo ·

Docente: David S. Fernández Mc Cann

---

1. Introducción

Este informe documenta el avance del subproyecto de visión artificial del sistema IdentiMar, orientado a construir un módulo capaz de recibir una imagen de raya proveniente del backend (Equipo 3) y devolver una especie propuesta, un nivel de confianza y un estado (`identificado` o `no_concluyente`) según un umbral de incertidumbre definido. El trabajo cubre, hasta el momento, la delimitación de especies objetivo, la construcción y documentación del dataset, el entrenamiento y comparación de modelos YOLOv8, el análisis de errores y la validación con imágenes externas al dataset.

2. Selección de especies objetivo

Siguiendo la indicación de la ficha del proyecto de no prometer el reconocimiento de "todas las rayas" sino delimitar un conjunto según disponibilidad real de datos, se investigaron inicialmente cinco especies reportadas para el Golfo de Urabá: raya látigo, raya gavilán, raya chupare, raya de profundidad y raya del Magdalena.

La **raya de profundidad** (candidata *Rajella purpuriventralis*) fue descartada: es una especie bentónica de aguas entre 730 y 2.010 m de profundidad, sin respaldo fotográfico confirmado en ninguna colección ni en FishBase, y fuera del alcance de cualquier captura de pesca artesanal de superficie. Incluirla habría significado una clase sin ninguna imagen real disponible.

Las cuatro especies finales, con su nombre científico verificado contra literatura del Caribe colombiano, son:

Nombre común	Nombre científico	Familia	Justificación
Raya látigo	*Hypanus guttatus*	Dasyatidae	Especie más frecuente en capturas de rayas del norte del Caribe colombiano (Moreno, Acevedo & Paramo, 2008)
Raya gavilán	*Aetobatus narinari*	Aetobatidae	Ampliamente documentada en el Caribe colombiano; patrón de manchas altamente distintivo

Nombre común	Nombre científico	Familia	Justificación
Raya chupare	*Styracura schmardae*	Potamotrygonidae	Confirmada para el Atlántico/Caribe; proyecto de ciencia ciudadana con 769 registros fotográficos regionales
Raya del Magdalena	*Potamotrygon magdalenae*	Potamotrygonidae	Endémica de Colombia; presente en la cuenca del Atrato, que desemboca en el Golfo de Urabá

Rasgos morfológicos diagnósticos

Para guiar los criterios de calidad y encuadre de las imágenes, se identificaron los rasgos que deben ser visibles para una identificación confiable:

- **Raya látigo**: hocico puntiagudo que sobresale, y fila de tubérculos/espinas dorsales entre los ojos y la base de la cola. Rasgo que se confunde fácilmente con *H. americanus* si el hocico no es visible.
- **Raya gavilán**: patrón de manchas/anillos blancos sobre fondo oscuro en el dorso — rasgo único entre las cuatro especies, visible incluso en encuadres parciales.
- **Raya chupare**: tubérculos grandes en forma de perla en los hombros, y disco ovalado/casi circular (vs. romboidal de la látigo).
- **Raya del Magdalena**: sin descripción de patrón de color verificada en fuentes consultadas; se decidió comparar visualmente ejemplares confirmados en el propio proceso de curaduría.

3. Metodología de construcción del dataset

3.1 Búsqueda y fuentes de imágenes

Se verificó mediante consulta directa a las APIs públicas de GBIF e iNaturalist (globales y filtradas a Colombia) la disponibilidad real de imágenes por especie antes de fijar metas:

Especie	GBIF (global)	GBIF (Colombia)	iNaturalist (global)	iNaturalist (Colombia)
Hypanus guttatus	92	7	155	17
Aetobatus narinari	1.785	10	2.620	18
Styracura schmardae	680	9	1.078	10
Potamotrygon magdalenae	17	17	31	29

Este diagnóstico identificó tempranamente a *P. magdalenae* como cuello de botella: prácticamente todos sus registros mundiales provienen de Colombia (especie endémica), por lo que no existe "más mundo" de donde obtener imágenes adicionales fuera de fuentes colombianas.

Fuentes utilizadas, según el inventario por imagen: iNaturalist (250 imágenes, 87 %), GBIF (16), MNHN y Wikimedia Commons (1 cada una) y 18 imágenes de páginas web diversas, todas de *P. magdalenae* y de licencia no verificada. No quedaron registradas imágenes de SiB Colombia ni de literatura académica.

3.2 Inventario y documentación

Se construyó una plantilla de inventario (hoja de cálculo) con un registro por imagen, incluyendo: especie, fuente, autor/observador, licencia, fecha, ubicación, ambiente, condición del organismo, criterios de calidad (resolución, iluminación, enfoque, encuadre, integridad del organismo visible), y partición asignada (train/validación/prueba).

Criterio de calidad adoptado: se incluyeron deliberadamente imágenes de calidad "de smartphone real" (desenfoque leve, iluminación variable, fondo turbio) en el conjunto de entrenamiento, replicando las condiciones reales de uso por parte de pescadores — entrenar únicamente con fotografías de galería habría generado una brecha entre el desempeño medido y el desempeño real en campo (*train-serving skew*).

3.3 Estadísticas finales del dataset

Especie	Meta	Total	Train	Validación	Prueba	Avance
Hypanus guttatus	80	81	56	17	8	101%
Aetobatus narinari	80	80	56	16	8	100%
Styracura schmardae	80	80	56	16	8	100%
Potamotrygon magdalenae	50	45	31	9	5	90%
Total	**290**	**286**	**199**	**58**	**29**	—

La meta de *P. magdalenae* se ajustó de un valor inicial de 80 a 50 (y finalmente 45 imágenes reales) de forma explícita, documentando la limitación real de datos en lugar de forzar un número inalcanzable para una especie endémica con disponibilidad fotográfica mundial reducida.

4. Preprocesamiento y aumentación de datos

Se aplicó preprocesamiento estándar (auto-orientación, redimensionado a 640×640) y aumentación de datos únicamente sobre el conjunto de entrenamiento, con parámetros ajustados a los rasgos diagnósticos de cada especie:

Transformación	Configuración	Justificación
Flip horizontal	Activado	Sin rasgo diagnóstico asimétrico
Flip vertical	Desactivado	Orientación no realista
Rotación	±15°	Evita deformar la proporción del disco (rasgo diagnóstico)
Shear	Mínimo/desactivado	El shear deforma la geometría del disco

Transformación	Configuración	Justificación
Grayscale	Desactivado	El patrón de manchas de *A. narinari* depende del color
Hue	±10°	Leve, para no acercar tonalidades entre especies
Saturación	±20%	—
Brillo / Exposición	±20% / ±10%	Simula condiciones reales de pesca (sol directo, sombra)
Blur	Hasta 1.5 px	Complementa, no reemplaza, las fotos reales borrosas son reservadas para prueba
Noise	Hasta 3%	Simula cámaras de celular económicas

Sobremuestreo dirigido

Dado el volumen limitado de *P. magdalenae* (ID de clase 2), se aplicó sobremuestreo manual sobre el conjunto de entrenamiento ya exportado. Tras una descarga limpia del dataset, la carpeta `train` contenía 597 imágenes (las imágenes fuente de entrenamiento con sus versiones aumentadas en Roboflow), de las cuales 93 incluían la clase; cada una se copió tres veces (3×) con un script idempotente (elimina las copias previas y duplica únicamente los archivos originales), lo que agregó 279 copias y llevó `train` a 876 imágenes. La clase Magdalena pasó a 372 imágenes (42,5 % de `train`; 660 instancias), frente a 168 imágenes (19,2 %) de cada una de las otras tres especies. El sobremuestreo se aplicó exclusivamente a la carpeta `train`, preservando intactas las particiones de validación y prueba para no comprometer la evaluación.

Se experimentó también extender el sobremuestreo a *Hypanus guttatus* para compensar la dilución proporcional causada por el crecimiento de la clase Magdalena. En ese experimento (dos corridas, una de ellas con semilla fija `seed=0`) el desempeño general empeoró (mAP50-95 de validación: 0.628 → 0.527) sin mejora para la propia clase látigo, por lo que se **revirtió**. **Salvedad:** esas corridas se hicieron con la versión anterior del script de sobremuestreo (ver la nota siguiente), por lo que la composición exacta de `train` no es reconstruible; el resultado se considera indicativo y no se repitió con el procedimiento corregido.

Nota sobre una versión anterior del script. En las corridas iniciales, el primer script de sobremuestreo contó 372 archivos con la clase Magdalena cuando solo había 93 originales (93 × 4), lo que indica que procesó también sus propias copias: generó 1.116 copias y dejó 1.713 imágenes en `train`, con la clase presente en ≈ 1.209 de ellas (≈ 71 %), es decir, un sobremuestreo efectivo de ≈ 13× en lugar de 3×. El modelo entrenado en esas condiciones (mAP50 = 0.931 y mAP50-95 = 0.773 en prueba) no se conservó y no pudo reproducirse exactamente. Todos los resultados finales de este informe provienen de un reentrenamiento con el script corregido (idempotente) y con la versión de Ultralytics fijada en 8.4.170.

5. Metodología de entrenamiento

Se utilizó Ultralytics YOLOv8 vía transferencia de aprendizaje, partiendo de pesos preentrenados en COCO. Parámetros base: `epochs=100`, `imgsz=640`, `batch=16`, `patience=20` y la versión 8.4.170 de Ultralytics (fijada para reproducibilidad). Se entrenó y evaluó con tres particiones independientes (train/validación/prueba), reportando las métricas de precisión, recall, F1, mAP50 y mAP50-95 sobre el conjunto de **prueba**, nunca visto durante el ajuste de hiperparámetros.

6. Resultados experimentales

6.1 Comparación de arquitecturas: YOLOv8n vs. YOLOv8s

Esta comparación se realizó en varios momentos del proyecto: primero sobre el dataset original (antes de corregir anotaciones y aplicar sobremuestreo) y luego sobre el dataset con sobremuestreo en su versión anterior . La última columna corresponde al modelo final, reentrenado con el procedimiento corregido; YOLOv8s no se reentrenó con él.

Métrica	YOLOv8n (dataset original)	YOLOv8s (dataset original)	YOLOv8n (sobremuestreo previo)	YOLOv8s (sobremuestreo previo)	YOLOv8n (modelo final)
mAP50 (prueba)	0.899	0.874	0.931	0.882	0.950
mAP50-95 (prueba)	0.672	0.632	0.773	0.637	0.759
Hypanus guttatus mAP50	0.813	0.771	0.995	0.759	0.967
Velocidad de inferencia	10.0 ms	11.9 ms	~10 ms	12.6 ms	6–13 ms

En todas las comparaciones disponibles, YOLOv8n igualó o superó a YOLOv8s en la métrica más exigente (mAP50-95) y fue más rápido en inferencia. Bajo las mismas condiciones, YOLOv8n alcanzó mAP50-95 = 0.773 frente a 0.637 de YOLOv8s, y en la clase *Hypanus guttatus* la brecha fue de 0.995 frente a 0.759. El modelo final reentrenado con el procedimiento corregido (mAP50 = 0.950; mAP50-95 = 0.759) mantiene ese nivel, lo que confirma la selección de **YOLOv8n** como arquitectura final por su desempeño igual o superior y su menor latencia.

6.2 Evolución del modelo a través de las iteraciones

Iteración	mAP50 (prueba)	mAP50-95 (prueba)
Baseline (YOLOv8n, dataset original)	0.899	0.672
Corrección de anotaciones + eliminación de 3 imágenes borrosas	0.885	0.630
(Script anterior, ≈ 13× efectivo; modelo no conservado) Sobremuestreo dirigido a *P. magdalenae*	0.931	0.773

Iteración	mAP50 (prueba)	mAP50-95 (prueba)
(Experimento revertido, script anterior) Sobremuestreo extendido a *H. guttatus*	0.918	0.638
Modelo final: sobremuestreo dirigido a *P. magdalenae* (3×, script corregido), Ultralytics 8.4.170	**0.950**	**0.759**

El modelo final seleccionado corresponde a la arquitectura YOLOv8n con sobremuestreo dirigido únicamente a la clase *Potamotrygon magdalenae* (3×, procedimiento corregido), entrenado con Ultralytics 8.4.170. Su resultado es equivalente, dentro del ruido esperable entre corridas, al del modelo anterior (≈ 13×): en validación el mAP50 fue 0.834 frente a 0.816 y el mAP50-95 0.598 frente a 0.618. Esto indica que el sobremuestreo dirigido aporta una mejora sin necesidad de multiplicar la clase de forma extrema.

6.3 Métricas del modelo final por especie (conjunto de prueba, n=29)

Especie	Precisión	Recall	F1	mAP50	mAP50-95
Aetobatus narinari	0.741	0.875	0.802	0.875	0.722
Hypanus guttatus	0.847	1.000	0.917	0.967	0.749
Potamotrygon magdalenae	0.825	0.948	0.882	0.962	0.693
Styracura schmardae	0.978	1.000	0.989	0.995	0.870
Promedio (macro)	0.847	0.956	0.897	0.950	0.759

Nota metodológica: dado que las particiones de prueba contienen apenas 5-8 instancias por especie, un recall perfecto (1.0) no debe interpretarse como garantía estadística, sino como una señal alentadora sobre una muestra pequeña. La validación (58 imágenes) es una muestra más estable: allí *P. magdalenae* es la clase más débil (recall 0.556, es decir 5 de 9 instancias; mAP50 = 0.566), por lo que su 0.962 de prueba debe leerse con cautela. La precisión, el recall y el F1 se calculan, como lo hace Ultralytics, al umbral de confianza que maximiza el F1 promedio, no al umbral 0.70 del contrato (ver sección 6.4).

Mismo modelo sobre el conjunto de **validación** (58 imágenes, 59 instancias):

Especie	Precisión	Recall	F1	mAP50	mAP50-95
Aetobatus narinari	0.939	0.969	0.954	0.984	0.706
Hypanus guttatus	0.866	0.720	0.786	0.835	0.545
Potamotrygon magdalenae	0.679	0.556	0.611	0.566	0.400
Styracura schmardae	0.876	0.875	0.876	0.950	0.739
Promedio (macro)	0.840	0.780	0.807	0.834	0.598

Velocidad de inferencia medida: entre 6 y 13 ms por imagen (≈ 75-170 imágenes por segundo) sobre GPU Tesla T4; la variación corresponde a diferencias entre ejecuciones de validación. Es un dato relevante para la prueba de integración end-to-end de tiempo de respuesta.

6.4 Evaluación operativa con la salida estándar del contrato

Además de las métricas estándar, se evaluó el sistema tal como lo consumirá el backend: sobre las 29 imágenes de prueba se aplicó la función de salida estándar, que toma la detección de mayor confianza y marca `no_concluyente` cuando la confianza es menor al umbral del contrato (0.70) o no hay detección. Se predijo con `conf=0.25` para poder informar la especie sospechada también en los casos no concluyentes.

Resultado	Imágenes	%
Identificado y correcto	21	72.4
Identificado e incorrecto (error de alta confianza)	1	3.4
No concluyente (habría acertado)	4	13.8
No concluyente (habría fallado)	2	6.9
No concluyente, sin detección	1	3.4

De 29 imágenes, 22 (76 %) se identifican de forma automática y 21 de ellas (95 %) son correctas; 7 se derivan a revisión experta. Variando el umbral:

Umbral	Identificadas	% identificadas	Correctas	% correctas entre identificadas	Errores con alta confianza	Derivadas a experto
0.5	27	93.1	24	88.9	3	2
0.6	24	82.8	22	91.7	2	5
0.7	22	75.9	21	95.5	1	7
0.8	18	62.1	17	94.4	1	11
0.9	10	34.5	10	100	0	19

El umbral 0.70 ofrece un compromiso razonable entre automatización y errores de alta confianza; subirlo a 0.9 elimina esos errores pero deriva a experto a dos de cada tres imágenes. Con solo 29 imágenes, estos valores son indicativos y deben recalibrarse con un conjunto mayor.

6.5 Conciliación de métricas entre versiones

Durante el proyecto se presentaron resultados de varias versiones del modelo, obtenidos en condiciones distintas. La tabla siguiente las concilia: cada fila indica con qué dataset, entorno y procedimiento de sobremuestreo se entrenó y qué papel cumple hoy. **Solo la versión V7 es el modelo definitivo**; las demás se conservan como historia del proceso.

Versión	Condiciones	Prueba (mAP50 / mAP50-95)	Validación (mAP50 / mAP50-95)	Estado
V1 · YOLOv8n baseline	Dataset original (v1); Ultralytics 8.4.163; sin sobremuestreo	0.899 / 0.672	0.806 / 0.557	Histórica
V1s · YOLOv8s	Igual que V1	0.874 / 0.632	0.777 / 0.546	Histórica (comparación de arquitecturas)
V2 · Anotaciones corregidas	Dataset v2 (anotaciones corregidas y 3 imágenes borrosas sustituidas); 8.4.163; sin sobremuestreo	0.885 / 0.630	0.756 / 0.564	Histórica
V3 · Sobremuestreo, script anterior (1.ª corrida)	Dataset v2; clase Magdalena ≈ 13× efectivo; versión de Ultralytics no registrada; sin semilla fija	0.956 / 0.810	0.806 / 0.628	Descartada: composición de train errónea
V4 · Misma configuración (2.ª corrida)	Igual que V3; `seed=0`; 8.4.170	0.931 / 0.773	0.816 / 0.618	Descartada: pesos no conservados
V4s · YOLOv8s sobre V4	Igual que V4	0.882 / 0.637	0.775 / 0.577	Descartada (comparación con V4)
V5 · Sobremuestreo extendido a *H. guttatus*	Script anterior; 8.4.170	0.918 / 0.638	0.747 / 0.527	Descartada (experimento revertido)
V6 · Reentrenamiento con Ultralytics 8.4.177	Script anterior; modelo de 73 capas y 3.133.436 parámetros	0.916 / 0.746	no reportada	Descartada: entorno distinto
V7 · Definitiva	Dataset v2; sobremuestreo 3× con script idempotente; 8.4.170; YOLOv8n (72 capas, 3.006.428 parámetros)	**0.950 / 0.759**	**0.834 / 0.598**	**Definitiva**

Condiciones de evaluación comunes: particiones de validación (58 imágenes) y prueba (29 imágenes) con el mismo tamaño en todas las versiones; mAP calculado con el umbral de confianza por defecto de Ultralytics (0.001); precisión, recall y F1 al umbral que maximiza el F1 promedio; matrices de confusión a

`conf = 0.25`; evaluación operativa con el umbral del contrato (0.70). Diferencias menores a ≈ 0.06 en mAP50-95 entre versiones no son concluyentes dada la variabilidad entre corridas y el tamaño de las particiones.

Limitación declarada: la comparación entre YOLOv8n y YOLOv8s se hizo en condiciones equivalentes entre sí (V1 y V1s; V4 y V4s). La elección de YOLOv8n se apoya, además, en su menor tamaño y latencia.

7. Análisis de errores

7.1 Confusión sistemática entre *Hypanus guttatus* y *Potamotrygon magdalenae*

El hallazgo más relevante del análisis de errores fue una confusión morfológica genuina y recurrente entre la raya látigo y la raya del Magdalena, detectada mediante inspección manual de las imágenes con error (falsas alarmas y detecciones perdidas) en el modelo baseline. Se identificó que ciertos ejemplares de *P. magdalenae* presentan cola larga y hocico más puntiagudo de lo típico — precisamente el rasgo definido como diagnóstico de *H. guttatus* — generando solapamiento morfológico real entre especies, no un simple error de anotación.

Tras el sobremuestreo dirigido, la confusión entre ambas especies se redujo de forma sustancial, pero **no desapareció por completo**: en 3 de las 13 imágenes externas el modelo final dibujó cajas de ambas especies sobre el mismo organismo (ver sección 8).

La matriz de confusión de validación del modelo final (conf = 0.25, 59 instancias) muestra 45 instancias bien clasificadas (76 %), 7 confundidas con otra especie y 7 no detectadas, además de 12 falsas detecciones sobre fondo. Las pérdidas se concentran en *H. guttatus* (4 de 18) y *P. magdalenae* (2 de 9); entre especies, la confusión más frecuente es *H. guttatus* ↔ *S. schmardae* (2 casos en cada sentido), mientras que la confusión látigo ↔ Magdalena se redujo a 1 caso (una *P. magdalenae* clasificada como *H. guttatus*) y ninguno en sentido contrario.

7.2 Clasificación de errores por severidad respecto al umbral de incertidumbre

Un hallazgo relevante para el diseño del sistema completo: no todos los errores de clasificación tienen el mismo impacto práctico. En la evaluación operativa sobre la partición de prueba (sección 6.4), con el umbral 0.70 del contrato, solo 1 de 29 imágenes es un **error con alta confianza** (identificada automáticamente con la especie incorrecta); en cambio, 2 errores de clasificación y 1 imagen sin detección quedan como `no_concluyente` y se derivan a revisión experta, y otros 4 casos que habrían acertado también se derivan por confianza baja, con un costo en carga de revisión. **Sin embargo, el conjunto ciego de 20 imágenes nuevas (sección 8.1) mostró un panorama menos favorable:** sus 5 errores llegaron como identificados, con confianzas entre 0.784 y 0.941, por lo que el umbral de 0.70 no los habría detenido. El umbral protege contra la duda, no contra el error convencido: la tasa de errores con alta confianza fue de 3.4 % en la partición de prueba y de 25 % en el conjunto ciego.

7.3 Sesgo de contexto: la especie y el contexto de la foto van juntos

Se identificó, mediante el análisis de errores en validación con una iteración anterior del modelo (sin revalidar con el modelo final), que el modelo falla al no detectar ejemplares fotografiados fuera del agua (p. ej. un organismo ya desembarcado sobre tierra y hojarasca). **El inventario del dataset muestra, además, que la especie y el contexto de la foto están correlacionados:** el porcentaje de fotos de

organismos vivos en el agua es de 95 % en *A. narinari*, 96 % en *S. schmardae*, 31 % en *H. guttatus* y 18 % en *P. magdalenae*. El modelo podría estar aprendiendo en parte el contexto (raya en el agua → gavilán o chupare; raya en tierra o en manos → látigo o Magdalena) y no solo la morfología. Esta hipótesis es coherente con la confusión de *H. guttatus* con *S. schmardae* en el conjunto ciego, pero debe verificarse inspeccionando las fotos que fallaron. Se documenta como sesgo del dataset y como línea de trabajo futuro.

En el conjunto ciego (sección 8.1), de las 20 imágenes evaluadas, 7 correspondían a ejemplares fotografiados fuera del agua. De estas, el modelo identificó correctamente 5 de ellas (71.4 % de aciertos en este subconjunto, frente a 76.9 % en las 13 imágenes restantes). Este desglose permite cuantificar de manera directa el impacto del contexto fuera del agua en el desempeño del modelo.

7.4 Casos de dificultad intrínseca (no atribuibles al dataset o modelo)

Se documentaron casos de camuflaje natural (organismo indistinguible del fondo de arena/roca por color y textura) y de agua turbia, donde incluso la identificación humana es ambigua a primera vista. Estos casos se consideran el límite realista del sistema y no un defecto corregible.

8. Validación con imágenes nuevas

8.1 Conjunto ciego de 20 imágenes nuevas

Para medir la generalización sin sesgo de selección se reunieron 20 fotografías nuevas, obtenidas después de congelar el modelo definitivo (V7) y evaluadas una sola vez a través de la API de inferencia con el umbral del contrato (0.70). No se usaron en entrenamiento, validación ni prueba, ni para elegir el modelo. Entre sí no presentan duplicados (0 pares sospechosos con hash perceptual) y se verificó que tampoco existen imágenes duplicadas al compararlas contra el dataset completo (entrenamiento, validación y prueba).

Especie real	Imágenes	Aciertos	Errores (especie predicha, confianza)
Aetobatus narinari	6	5	*H. guttatus* (0.941)
Hypanus guttatus	5	2	*S. schmardae* (0.905); *P. magdalenae* (0.874); *S. schmardae* (0.873)
Potamotrygon magdalenae	4	3	*S. schmardae* (0.784)
Styracura schmardae	5	5	—
Total	**20**	**15 (75 %)**	**5 errores, todos con confianza ≥ 0.70**

Resultado: 15 de 20 correctas (75 %). Los cinco errores se devolvieron como `identificado`, con confianzas entre 0.784 y 0.941: ninguno habría sido derivado a revisión experta (5 de 20, es decir 25 %, frente a 1 de 29, es decir 3.4 %, en la partición de prueba).

- La clase más débil es *H. guttatus* (2 de 5), confundida con *S. schmardae* y con *P. magdalenae*, en coherencia con el solapamiento morfológico descrito en la sección 7.1.

- *S. schmardae* actúa como clase atractora: el modelo la predijo 8 veces y 3 correspondían a otras especies.
- La brecha entre la partición de prueba (mAP50 de 0.950) y el conjunto ciego (75 % de aciertos) indica que las métricas de prueba sobrestiman el desempeño en fotografías nuevas: las particiones provienen de las mismas fuentes que el entrenamiento y son pequeñas. Con solo 20 imágenes, estos porcentajes tienen una incertidumbre amplia.
- Latencia: inferencia con mediana de 110 ms (p95 de 152 ms) en CPU local; tiempo de ida y vuelta cercano a 2.2 s, dominado por la decodificación de imágenes WEBP y la latencia de red.
- La confianza no separó los aciertos de los errores: los aciertos tuvieron confianza mediana de 0.92 (mínima 0.744) y los cinco errores, entre 0.784 y 0.941. En un análisis exploratorio sobre este mismo conjunto (no se usó para fijar el umbral), con un umbral de 0.90 aún pasarían 2 de los 5 errores y 9 de las 20 imágenes irían a un experto; solo con 0.95 desaparecerían los errores, a costa de derivar 17 de 20. Subir el umbral no corrige el problema.

8.2 Imágenes externas usadas durante el desarrollo

Durante el desarrollo se usaron 13 imágenes externas al dataset (nunca incluidas en entrenamiento, validación ni prueba) como verificación informal de cada versión. Como se consultaron al comparar versiones del modelo, **no constituyen una evaluación ciega** y se reportan solo como evidencia complementaria. Resultado del modelo final:

Especie	Imágenes externas	Especie correcta detectada	Con caja adicional de otra especie
Potamotrygon magdalenae	6	6	1
Aetobatus narinari	2	2	0
Hypanus guttatus	3	3	2
Styracura schmardae	2	2	0
Total	**13**	**13**	**3**

En estas 13 imágenes el modelo final detectó la especie correcta en todos los casos, con cajas adicionales de otra especie (*H. guttatus* y *P. magdalenae* sobre el mismo organismo) en 3 de ellas. Como el contrato toma únicamente la detección de mayor confianza, el efecto de esas cajas sobre la salida final depende de su confianza relativa. Este resultado debe leerse como verificación informal: el conjunto ciego (sección 8.1) muestra un desempeño menor.

9. Limitaciones conocidas y lecciones metodológicas

- **Tamaño de las particiones de prueba y validación de *P. magdalenae*** (5 y 9 instancias respectivamente): insuficiente para conclusiones estadísticamente robustas; las métricas de esta clase deben leerse con cautela.
- **Solapamiento morfológico parcial** entre *H. guttatus* y *P. magdalenae* en individuos de cola alargada: limitación biológica de la tarea, no exclusivamente de datos.

- **Variabilidad entre corridas de entrenamiento sin semilla fija**: el mAP50-95 en prueba varió entre 0.746 y 0.810 entre reentrenamientos con configuración nominalmente equivalente (incluyendo cambios de versión de librerías y del script de sobremuestreo), atribuible a la inicialización aleatoria y al tamaño reducido del conjunto de prueba; diferencias menores a ≈ 0.06 no deben leerse como mejoras reales. A partir de la corrida de comparación de sobremuestreo extendido, se adoptó `seed=0` para garantizar reproducibilidad en las comparaciones reportadas.
- **Correlación entre la especie y el contexto de la foto**: casi todas las fotos de *A. narinari* y *S. schmardae* están en el agua, y la mayoría de las de *H. guttatus* y *P. magdalenae*, fuera de ella; el modelo puede aprender el contexto además de la morfología.
- **Posible sesgo de cautiverio** en una fracción de las imágenes de *P. magdalenae*, proveniente de su comercialización como pez ornamental.
- **Comparaciones iniciales entre iteraciones realizadas sobre el conjunto de prueba (8 imágenes por clase)** llevaron a una conclusión incorrecta sobre el desempeño de *H. guttatus* en una etapa intermedia del proyecto; al repetir la comparación sobre el conjunto de validación (58 imágenes) la conclusión se revirtió. Se documenta como lección metodológica: las comparaciones entre configuraciones deben privilegiar la muestra de mayor tamaño disponible.
- **Reproducibilidad entre entornos y pérdida de un modelo intermedio**: al reiniciarse el entorno de Colab se perdió el `best.pt` de una corrida anterior, y un cambio de versión de Ultralytics (8.4.170 → 8.4.177) produjo un modelo con distinto número de capas y parámetros (73 y 3.133.436 frente a 72 y 3.006.428) y cambió el umbral con que se calcula la matriz de confusión. Como medidas correctivas se fijó la versión 8.4.170, los resultados se guardan en Google Drive y cada modelo congelado se acompaña de una ficha con hash, hiperparámetros y versiones del entorno.
- **Error en el primer script de sobremuestreo** (sección 4): inflaba la clase Magdalena a ≈ 13× en lugar de 3×; se corrigió con una versión idempotente y se reentrenó el modelo final.
- **Brecha entre la partición de prueba y las imágenes nuevas**: en un conjunto ciego de 20 fotografías el modelo acertó 15 (75 %) y sus 5 errores llegaron con confianza entre 0.784 y 0.941; el umbral de 0.70 no los detecta. Las métricas de la partición de prueba sobrestiman el desempeño con fotografías nuevas, y *H. guttatus* es la clase con peor desempeño (2 de 5).
- **Procedencia y licencias**: 234 de las 286 imágenes están bajo CC-BY-NC (uso no comercial), 2 bajo CC-BY-NC-ND y 20 imágenes de *P. magdalenae* provienen de páginas web cuya licencia no se verificó; el dataset y el modelo se usan solo con fines académicos.

10. Trabajo futuro

- Equilibrar el contexto dentro de cada especie: más fotos en el agua de H. guttatus y P. magdalenae, y fuera del agua de A. narinari y S. schmardae, para que el modelo no aprenda el fondo en lugar de la morfología.
- Evaluar el uso de SAM para aislar el organismo del fondo específicamente en los casos de confusión morfológica persistente.
- Recalibrar el umbral de incertidumbre (0.70) con un conjunto de validación mayor, ya que el barrido sobre 29 imágenes es solo indicativo.

- Ampliar y diversificar las imágenes de *H. guttatus* (la clase con peor desempeño en el conjunto ciego) y estudiar cómo reducir los errores con alta confianza, por ejemplo recalibrando la confianza con un conjunto de validación nuevo.

11. Conclusiones

Se construyó y documentó un dataset de 286 imágenes para cuatro especies de rayas del Urabá antioqueño, delimitadas por disponibilidad real de datos verificada contra fuentes públicas (GBIF, iNaturalist). Se entrenaron y compararon múltiples configuraciones de YOLOv8, seleccionando YOLOv8n con sobremuestreo dirigido (3×) a la clase más escasa como modelo final, que alcanza mAP50 = 0.950 y mAP50-95 = 0.759 sobre la partición de prueba (0.834 y 0.598 en validación). Con la salida estándar del contrato y el umbral 0.70, el sistema identifica automáticamente el 76 % de las imágenes de prueba con 95 % de aciertos. **Sin embargo, en un conjunto ciego de 20 imágenes nuevas acertó 15 (75 %) y sus 5 errores llegaron con confianza entre 0.784 y 0.941, de modo que el umbral actual no los habría derivado a un experto**; las métricas de la partición de prueba sobrestiman el desempeño con fotografías nuevas. El análisis de errores permitió identificar una confusión morfológica entre *H. guttatus* y *P. magdalenae*, un sesgo de contexto por resolver y limitaciones de reproducibilidad (versión de librerías, un error corregido en el script de sobremuestreo y el tamaño reducido de las particiones de prueba). Las principales líneas de mejora son ampliar y diversificar las imágenes de *H. guttatus* y reducir los errores con alta confianza.